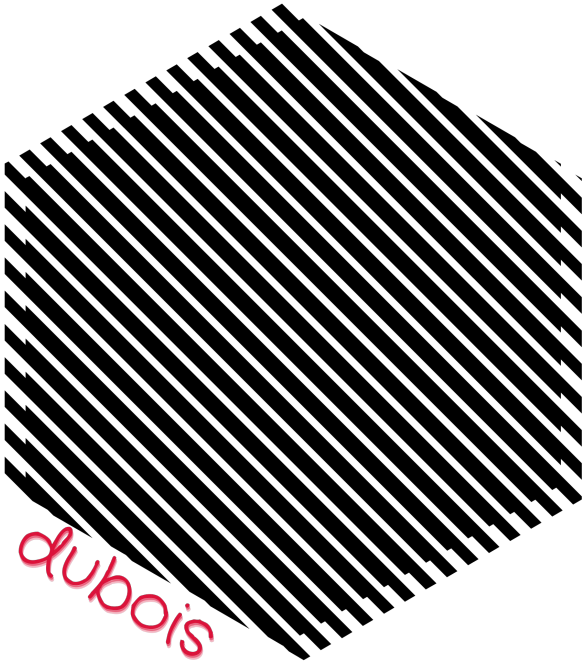

Visualização de dados através do pacote dubois

por Ícaro Bernardes

Maio de 2022

International Seminar on Statistics with R

BIT::Analytics
{Past, present and future data-driven}

Bacharelado em Eng. Química — **UFBA**

Mestrando em Eng. Industrial — **UFBA**

Co-fundador e cientista de dados — **BIT::Analytics**

Afiliação e trabalhos em *dataviz*

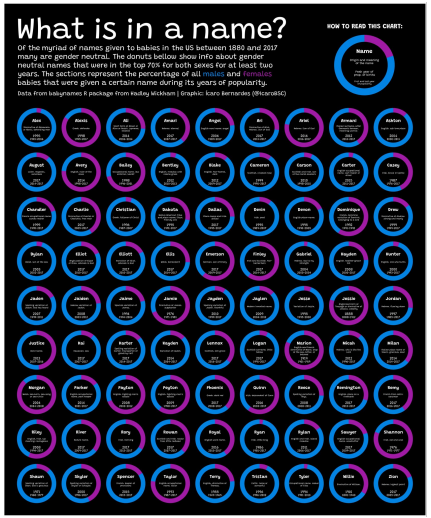

TidyTuesday

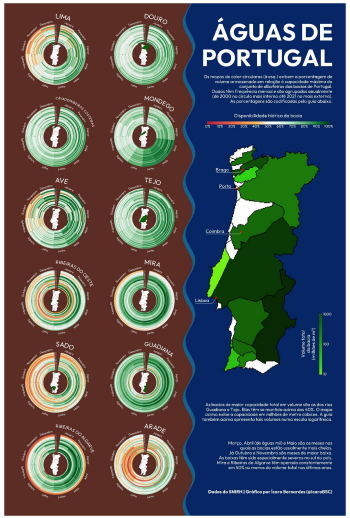

30DayChartChallenge

DuBoisChallenge

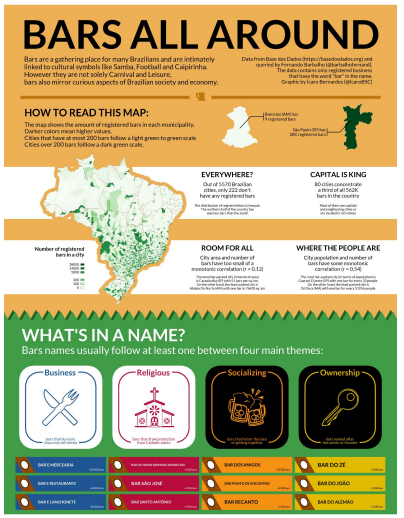

Extras

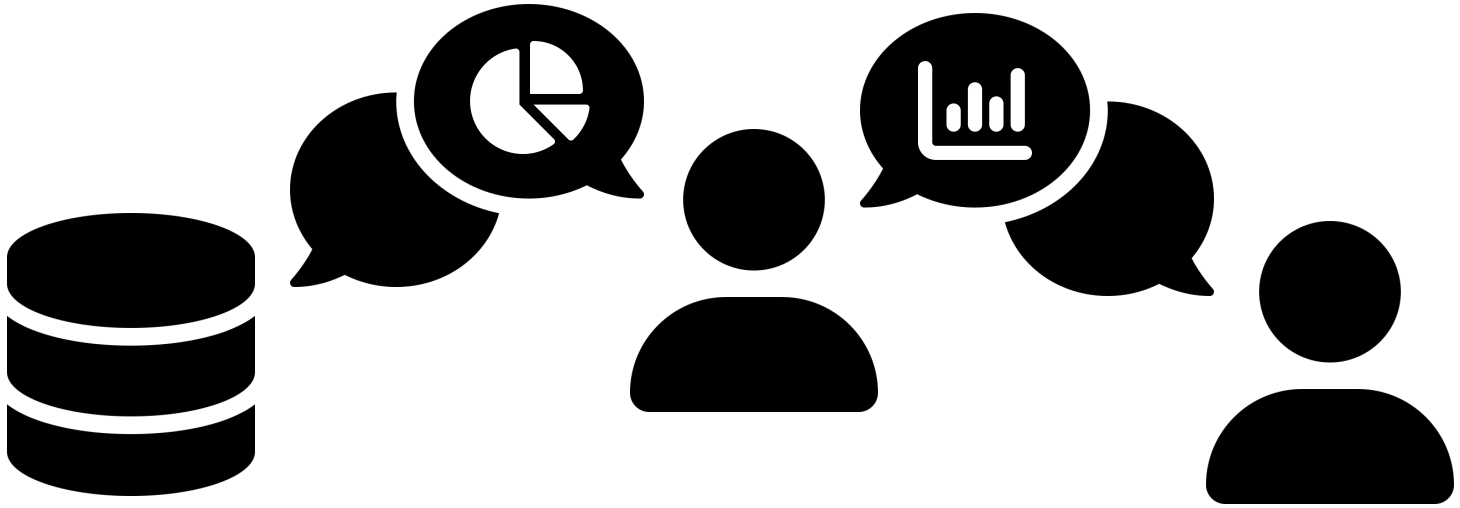

Ícones do Font Awesome

Produzir uma visualização para dados é

comunicar

Das escolhas feitas derivam

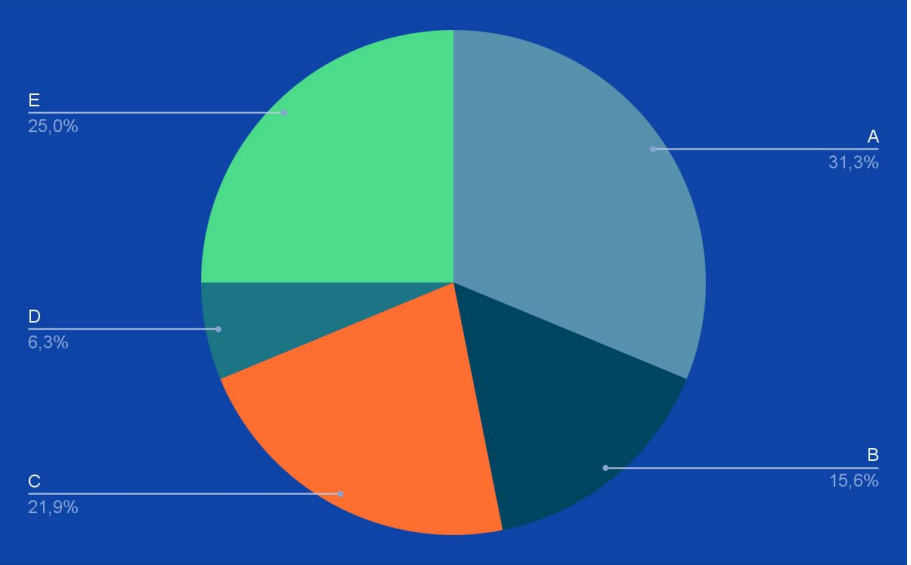

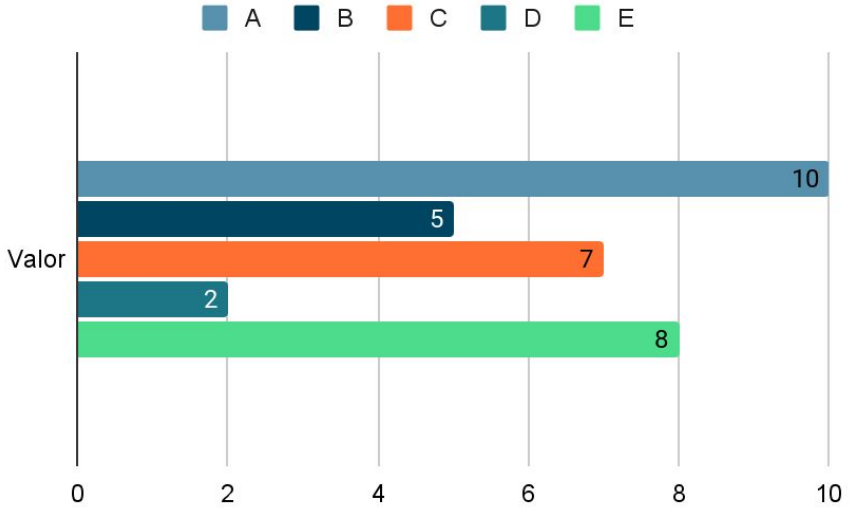

mal-entendidos ou **compreensão**

Du Bois

Sociólogo americano e
gênio do *dataviz*

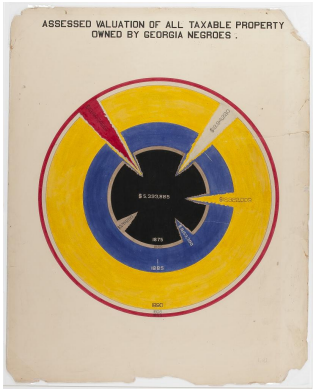

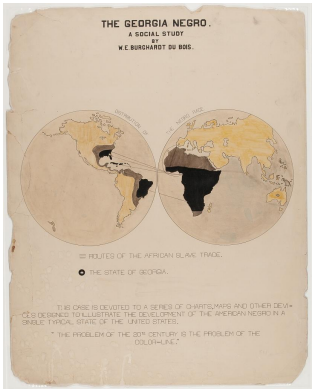

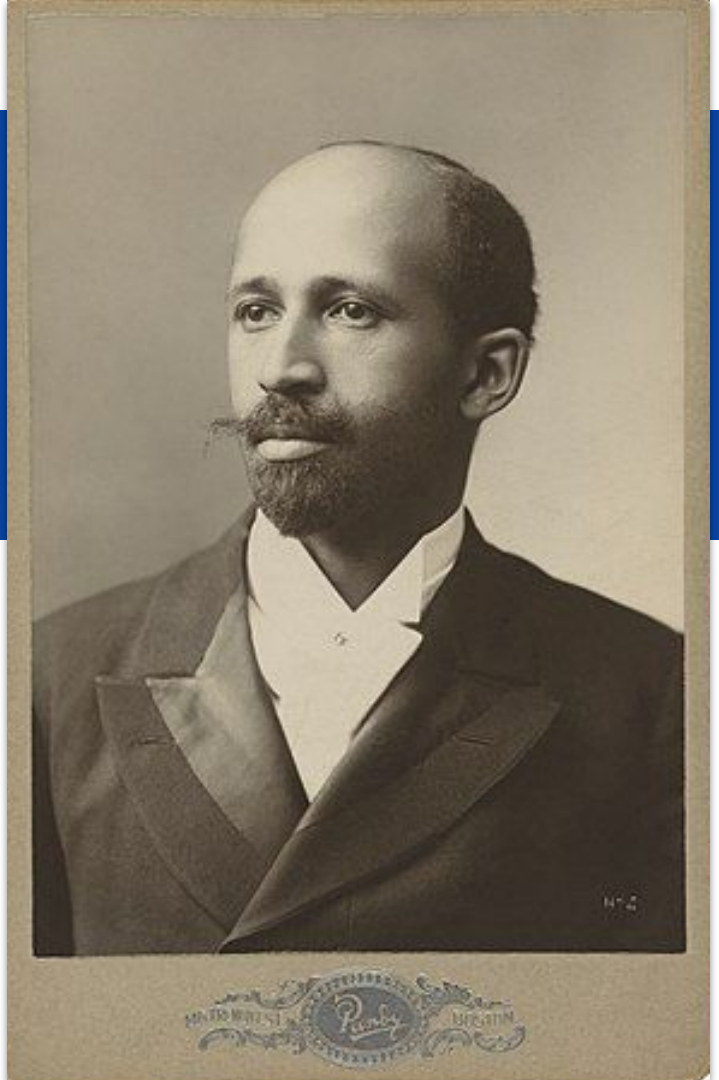

Entendendo a função
dubois::db_area

0. **Argumentos da função** (linhas 33-154)
1. **Uso de {showtext}** (linhas 156-170)
2. **Manejo dos dados** (linhas 172-302)
3. **Produção do gráfico** (linhas 304-374)

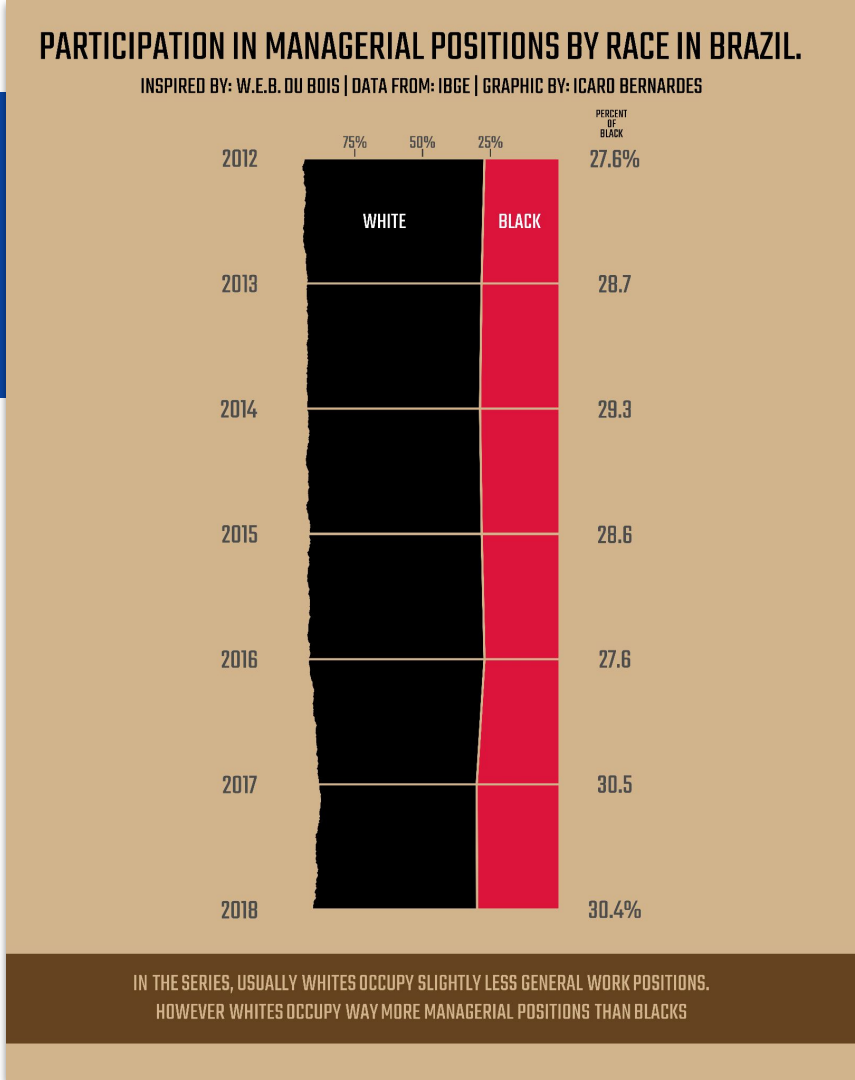

```r
# Carrega o pacote e outros auxiliares
library(dubois)

# Busca os dados sobre trabalhadores
# em cargos de comando contido no pacote
data <- dubois::managers

# Faz pequenas manipulações nos dados
data <- data %>%
  dplyr::select(race, year, pct_bosses_total) %>%
  tidyr::pivot_wider(names_from = "race",
                     values_from = "pct_bosses_total")

# Define título, subtítulo e mensagem
title <- "PARTICIPATION IN MANAGERIAL POSITIONS BY RACE IN
BRAZIL."
subtitle <- "INSPIRED BY: W.E.B. DU BOIS | DATA FROM: IBGE |
GRAPHIC BY: ICARO BERNARDES"
message <- "IN THE SERIES, USUALLY WHITES OCCUPY SLIGHTLY LESS
GENERAL WORK POSITIONS. HOWEVER WHITES OCCUPY WAY MORE
MANAGERIAL POSITIONS THAN BLACKS"

# Faz uso da função. A figura é
# salva no working directory
dubois::db_area(data = data, order = "year",
                cat1 = "black", cat2 = "white",
                limits = c(-3,4), filename = "managers.png",
                title = title, subtitle = subtitle,
                message = message)
```

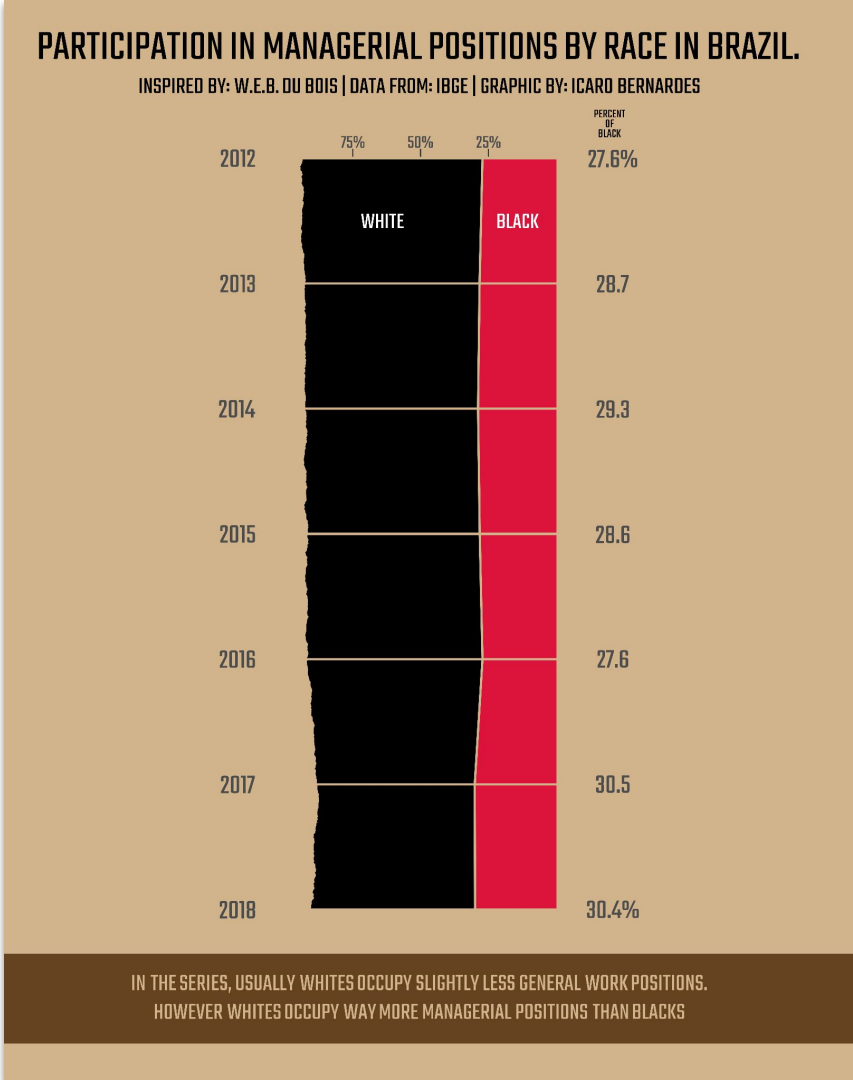

Entendendo a função
dubois::db_area

0. **Argumentos da função** (linhas 63-154)
1. **Uso de {showtext}** (linhas 156-170)
2. **Manejo dos dados** (linhas 172-302)
3. **Produção do gráfico** (linhas 304-374)

```r
# 0. Verificação inicial dos argumentos
## Converte limits a numérico (evita casos onde o número tem classe inteira)
limits = as.numeric(limits) %>% stats::na.exclude()

## Confirma a classe dos argumentos
verify_class_fun <- function(arg, class) {
  sym = rlang::sym(arg)
  if (!(class %in% class(rlang::eval_tidy(sym)))) {
    stop(glue::glue("{arg} has to be a {class} or similar"), call. = FALSE)
  }
}
verify_class_data <- tibble::tibble(
  arg = c("data", "order", "cat1", "cat2",
          "dpi", "seed", "res_step", "limits",
          "names", "title", "subtitle", "message", "path", "filename"),
  class = c("data.frame", rep("character",3), rep("numeric",4), rep("character",6))
)
purrr::pwalk(verify_class_data, ~verify_class_fun(.x, .y))

## Confirma que as variáveis estão realmente presentes em data
verify_varnames_fun <- function(name, var) {
  status = var %in% colnames(data)
  if (!status) {
    stop(glue::glue("Needed variable absent: {name}"), call. = FALSE)
  }
}
verify_varnames_data <- tibble::tibble(
  name = c("order", "cat1", "cat2"),
  var = c(order, cat1, cat2)
)
purrr::pwalk(verify_varnames_data, ~verify_varnames_fun(.x, .y))
```

```r
## Confirma que ambas categorias são numéricas
verify_varnum_fun <- function(name, var) {
  sym = rlang::sym(var)
  status = data %>%
    dplyr::select("num" = !!sym) %>%
    dplyr::pull(num) %>%
    is.numeric()
  if (!status) {
    stop(glue::glue("Variable has to be numeric: {name}"), call. = FALSE)
  }
}
verify_varnum_data <- tibble::tibble(
  name = c("cat1", "cat2"),
  var = c(cat1, cat2)
)
purrr::pwalk(verify_varnum_data, ~verify_varnum_fun(.x, .y))

## Alerta o usuário em caso de dpi e seed não-inteiras
verify_whole_fun <- function(name, var) {
  tol = .Machine$double.eps^0.5
  result = abs(var - round(var)) < tol
  if (!result) {
    warning(glue::glue("{name} was not an integer"), call. = FALSE)
  }
}
verify_whole_data <- tibble::tibble(
  name = c("dpi", "seed"),
  var = c(dpi, seed)
)
purrr::pwalk(verify_whole_data, ~verify_whole_fun(.x, .y))
```

```r
## Confirma que limits e names tem o comprimento correto
verify_length_fun <- function(name, var) {
  amount = var %>% length()
  if (amount != 2) {
    stop(glue::glue("{name} must be a vector with two items"), call. = FALSE)
  }
}
verify_length_data <- tibble::tibble(
  name = c("limits", "names"),
  var = list(limits, names)
)
purrr::pwalk(verify_length_data, ~verify_length_fun(.x, .y))

## Confirma que os limites inferior e superior estão na ordem correta
if (limits[1] > limits[2]) {
  stop("limits must be given in the following order: inferior, superior", call. = FALSE)
}

## Confirma que filename tem uma extensão válida para uso por parte de ggplot2::ggsave
file_exts <- c(".eps", ".ps", ".tex", ".pdf", ".jpeg",
               ".tiff", ".png", ".bmp", ".svg", ".wmf")
if (stringr::str_detect(filename, paste0(file_exts, collapse = "|"), negate = TRUE)) {
  stop(glue::glue("filename must contain one of these extensions: {paste0(file_exts, collapse = ', ')}"), call. =
FALSE)
}
```

Entendendo a função
dubois::db_area

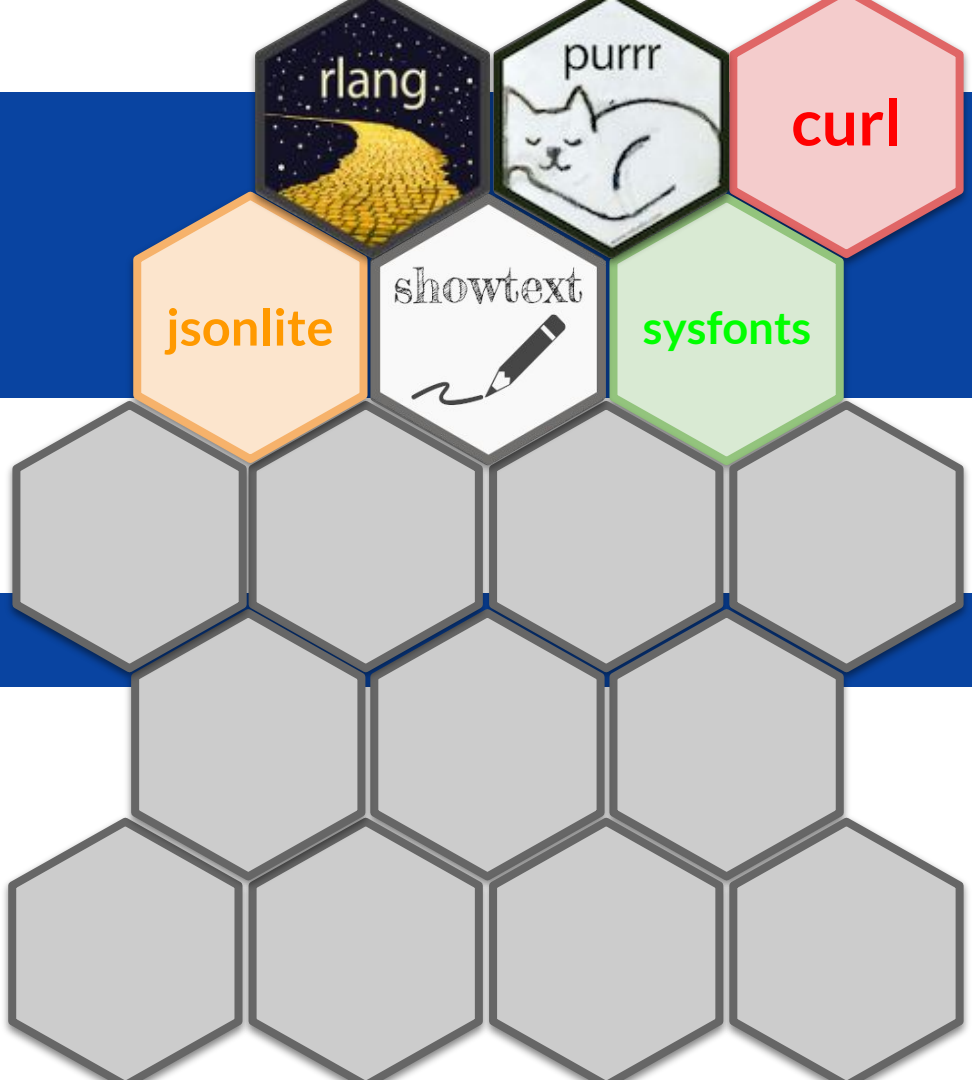

0. Argumentos da função (linhas 63-154)
1. Uso de {showtext} (linhas 156-170)
2. Manejo dos dados (linhas 172-302)
3. Produção do gráfico (linhas 304-374)

```r
# 1. Cuida da impressão do texto na imagem
## Verifica se a fonte "Teko" está disponível para ser
## usada por showtext e baixa ela se estiver ausente
if (!("Teko" %in% sysfonts::font_families())) {
  sysfonts::font_add_google(name = "Teko")
}

## Define a resolução de textos impressos por showtext nos dispositivos gráficos
showtext::showtext_opts(dpi = dpi)

## Ativa o controle da impressão do texto por parte de showtext.
## ATENÇÃO! showtext tem problemas na interalção com alguns plots
## (notadamente do pacote circlize), então é melhor criar eles
## primeiro e depois usar esse pacote
showtext::showtext_auto()
```

Entendendo a função
dubois::db_area

0. **Argumentos da função** (linhas 63-154)
1. **Uso de {showtext}** (linhas 156-170)
2. **Manejo dos dados** (linhas 172-302)
3. **Produção do gráfico** (linhas 304-374)

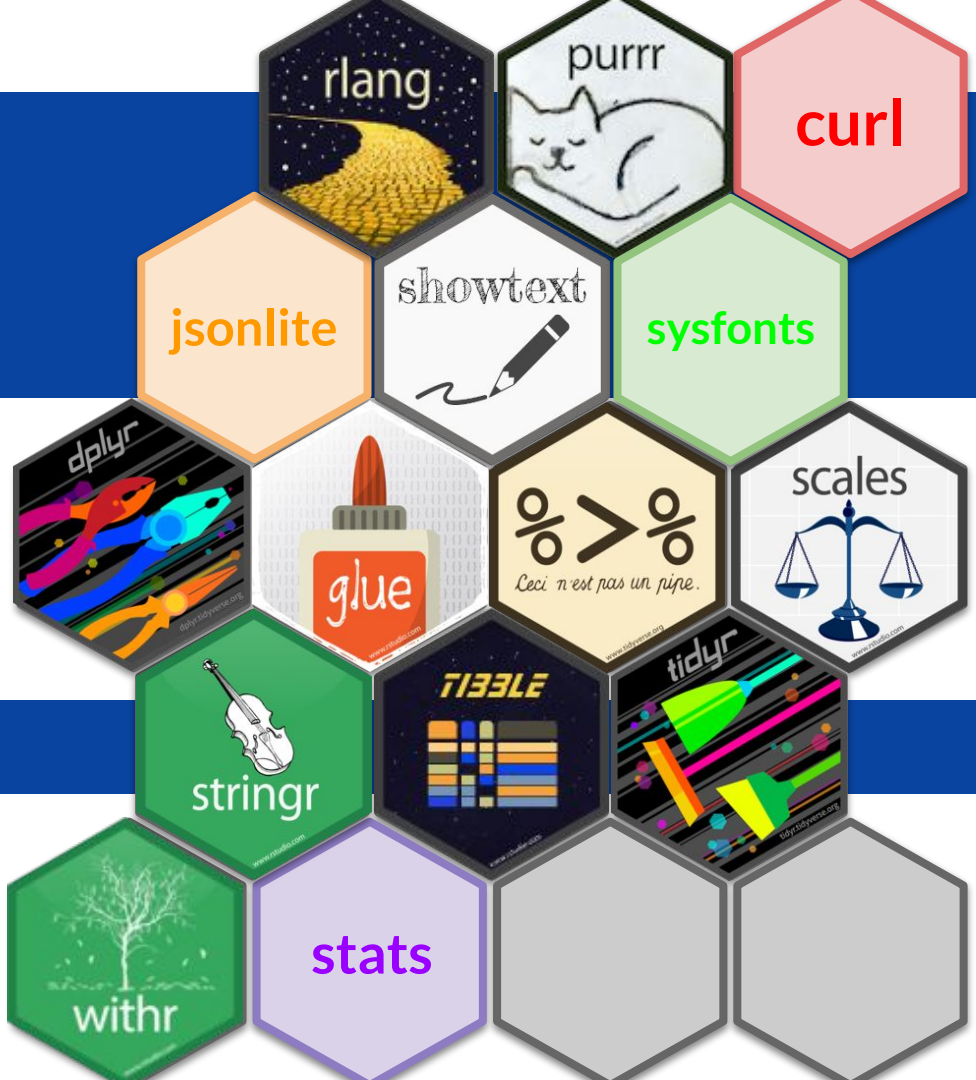

```r
# 2. Maneja os dados
## Elimina linhas com dados ausentes
data <- data %>%
  dplyr::filter(dplyr::if_all(.fns = ~ !is.na(.)))

## Obtém o número total de observações
n_obs <- dim(data)[1]

## Mantém apenas os dados da ordem das observações e os
## valores das duas categorias. Também as renomeia
data <- data %>%
  dplyr::select(order, cat1, cat2) %>%
  dplyr::rename(
    "order" = order,
    "cat1" = cat1,
    "cat2" = cat2
  )
```

```r
## Verifica se a soma do par de categorias é igual a 100%.
## Caso não seja, converte as categorias a porcentagens que o são.
check <- data %>%
  dplyr::mutate(
    pair = cat1 + cat2,
    pair == 100
  ) %>%
  dplyr::summarise(pair = sum(pair)) %>%
  dplyr::mutate(pair = (pair == n_obs)) %>%
  dplyr::pull(pair)

if (!check) {
  data <- data %>%
    dplyr::mutate(
      total = cat1 + cat2,
      cat1 = 100 * cat1 / total,
      cat2 = 100 * cat2 / total
    ) %>%
    dplyr::select(-total)
}

## Garante que a variável de ordem é ordenada. Se é um character,
## converte a factor e toma os níveis na ordem que eles aparecem
if (!is.numeric(data$order)) {
  if (!is.factor(data$order)) {
    data <- data %>%
      dplyr::mutate(order = factor(order, levels = unique(order)))
  }
}
data <- data %>% dplyr::arrange(order)
```

```r
## Cria os rótulos para a categoria destacada
highlight <- data %>%
  dplyr::mutate(
    cat1 = round(cat1, digits = 1),
    cat1 = ifelse(dplyr::row_number(order) == 1L | dplyr::row_number(order) == dplyr::n(),
                  paste0(cat1, "%"),
                  cat1
    )
  ) %>%
  dplyr::pull(cat1)

## Obtém o primeiro e último itens entre as
## categorias da ordem e converte elas a números
ord1 <- data %>%
  dplyr::slice(1L) %>%
  dplyr::mutate(order = as.numeric(order)) %>%
  dplyr::pull(order)
ord2 <- data %>%
  dplyr::slice(dplyr::n()) %>%
  dplyr::mutate(order = as.numeric(order)) %>%
  dplyr::pull(order)
```

```r
## Calcula uma área à esquerda do gráfico
## usando algo como um bounded random walk
withr::local_seed(seed)
lft_area <- tibble::tibble(
  y = seq(ord1, ord2, res_step * (ord2 - ord1))
) %>%
  dplyr::rowwise() %>%
  dplyr::mutate(r = stats::rnorm(n = 1)) %>%
  dplyr::ungroup() %>%
  dplyr::mutate(
    z = cumsum(r),
    z = scales::rescale(z, to = c(limits[1], limits[2]))
  ) %>%
  dplyr::mutate(
    x = z + 2 * mean(data$cat1) / 3 + mean(data$cat2),
    x = ifelse(x > 100, 100, x)
  )
```

```r
## Define os nomes das categorias
categ_names <- data %>%
  dplyr::slice(1L:2L) %>%
  dplyr::summarise(
    x1 = mean(cat1) / 2,
    x2 = mean(cat2) / 2 + mean(cat1),
    y = mean(as.numeric(order))
  ) %>%
  tidyr::pivot_longer(
    cols = c("x1", "x2"),
    names_to = "varname",
    values_to = "x"
  ) %>%
  dplyr::select(-varname) %>%
  dplyr::mutate(label = toupper(names))

## Define o título, título do eixo secundário e mensagem do gráfico
title <- paste0(toupper(title), "<br><span style='font-size:60px;'>", toupper(subtitle), "</span>")
sectitle <- paste0("PERCENT<br>OF<br>", toupper(names[1]))
message <- toupper(message) %>%
  stringr::str_wrap() %>%
  stringr::str_replace_all(pattern = "\n", "<br>")
```

```r
## Define algumas constantes de layout
lnhgt <- 0.8
bgcolor <- "#d2b48c"
l_marg <- 750 - 10 * max(stringr::str_length(data$order))
lb_sz <- 60 - 2 * max(stringr::str_length(data$order))
if (lb_sz < 30) {
  lb_sz <- 30
}

## Reorganiza os dados
data <- data %>%
  tidyr::pivot_longer(
    cols = c("cat1", "cat2"),
    names_to = "categ",
    values_to = "pct"
  )

## Cria uma nova variável numérica com base na ordem
data <- data %>%
  dplyr::mutate(num_order = as.numeric(order))
```

Entendendo a função
dubois::db_area

0. **Argumentos da função** (linhas 63-154)
1. **Uso de {showtext}** (linhas 156-170)
2. **Manejo dos dados** (linhas 172-302)
3. **Produção do gráfico** (linhas 304-374)

```r
# 3. Produção do gráfico
## Cria o gráfico
p <- data %>%
  ggplot2::ggplot() +

  ### Insere o par de áreas
  ggplot2::geom_area(ggplot2::aes(x = pct, y = num_order, fill = categ),
                     orientation = "y", size = 4, color = bgcolor,
                     position = ggplot2::position_stack(reverse = TRUE)
  ) +

  ### Insere o efeito de "rasgo" à esquerda
  ggplot2::geom ribbon(ggplot2::aes(xmin = x, xmax = 100, y = y),
                       fill = bgcolor, data = lft_area
  ) +

  ### Insere o nome das categorias
  ggplot2::geom_text(ggplot2::aes(x = x, y = y, label = label),
                     color = "white",
                     size = 15, family = "Teko", data = categ_names
  ) +

  ### Insere títulos e mensagem
  ggplot2::labs(title = title, subtitle = sectitle, caption = message, x = NULL, y = NULL) +
```

```r
### Reverte a escalas dos eixos e controla elementos delas
ggplot2::scale_x_reverse(
  expand = ggplot2::expansion(0, 10), breaks = seq(25, 75, 25),
  label = scales::label_percent(scale = 1), position = "top"
) +
ggplot2::scale_y_reverse(
  expand = ggplot2::expansion(0, 0.01),
  breaks = unique(data$num_order),
  labels = unique(data$order),
  sec.axis = ggplot2::dup_axis(
    name = NULL,
    breaks = unique(data$num_order),
    labels = highlight
  )
) +

### Aplica cores definidas para as áreas
ggplot2::scale_fill_manual(
  values = c("#dc143c", "black"),
  guide = "none"
) +
```

```r
### Customiza elementos do gráfico
ggplot2::theme(
  text = ggplot2::element_text(family = "Teko"),
  plot.margin = ggplot2::margin(t = 60, r = 400, b = 50, l = 400, unit = "pt"),
  plot.background = ggplot2::element_rect(fill = bgcolor, color = NA),
  plot.title = ggtext::element_textbox_simple(
    size = 80, halign = 0.5, valign = 0.5, width = 3, lineheight = lnhgt,
    margin = ggplot2::margin(t = 0, r = 0, b = 20, l = 0, unit = "pt")
  ),
  plot.subtitle = ggtext::element_textbox_simple(
    size = 23, halign = 0.5, valign = 0.5, width = 1.5, lineheight = lnhgt,
    padding = ggplot2::margin(t = 0, r = 0, b = -10, l = l_marg, unit = "pt")
  ),
  plot.caption = ggtext::element_textbox_simple(
    size = 45, fill = "#654321", color = bgcolor,
    halign = 0.5, valign = 0.5, width = 3,
    padding = ggplot2::margin(t = 40, r = 0, b = 40, l = 0, unit = "pt"),
    margin = ggplot2::margin(t = 80, r = 0, b = 20, l = 0, unit = "pt")
  ),
  panel.background = ggplot2::element_blank(),
  panel.grid.minor = ggplot2::element_blank(),
  panel.grid.major.x = ggplot2::element_blank(),
  panel.grid.major.y = ggplot2::element_line(color = bgcolor, size = 2),
  panel.ontop = TRUE,
  axis.text.x = ggplot2::element_text(size = 35),
  axis.text.y = ggplot2::element_text(size = lb_sz),
  axis.text.y.right = ggplot2::element_text(hjust = 0.5),
  axis.ticks.length.x = ggplot2::unit(15, "pt"),
  axis.ticks.x = ggplot2::element_line(size = 1),
  axis.ticks.y = ggplot2::element_blank()
)
```

```r
## Salva o gráfico
file <- paste0(path, "/", filename)
ggplot2::ggsave(file,
                plot = p, dpi = dpi,
                width = 22, height = 28
)
```

Muito obrigado!

@IcaroBSC

https://github.com/IcaroBernardes

icaro@bitanalytics.dev.br

https://www.linkedin.com/in/icarobsc